

Heart Disease Prediction

Bundit Rotyoon 6636060

Outline



- Introduction
- Exploring data
- · Select and Train Model
- Result
- Conclusion





Heart Disease Dataset





Heart Disease Dataset

• เริ่มเก็บตั้งแต่ 1988





Heart Disease Dataset

- เริ่มเก็บตั้งแต่ 1988
- ข้อมูลจาก 4 แหล่ง
 Cleveland, Hungary, Switzerland, and Long Beach V
- จริงๆ มี 76 Attribute แต่เผยแพร่แค่ 14





Heart Disease Dataset

- เริ่มเก็บตั้งแต่ 1988
- ข้อมูลจาก 4 แหล่ง
 Cleveland, Hungary, Switzerland, and Long Beach V
- จริงๆ มี 76 Attribute แต่เผยแพร่แค่ 14
- Labeled Data (0 = no disease and 1 = disease)



Labeled Data

(0 = no disease and 1 = disease)



Labeled Data

(0 = no disease and 1 = disease)





Labeled Data

(0 = no disease and 1 = disease)

↓

Classification Problem



Machine Learning Technique



Heart Disease Dataset

- 1,025 records
- 14 attributes



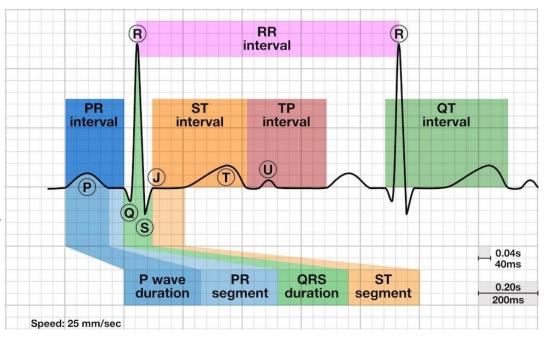
14 attributes

- age: age (age in years)
- sex: sex (1 = male; 0 = female)
- cp: chest pain type (4 values)
- trestbps: resting blood pressure
- chol: The person's cholesterol measurement in mg/dl
- fbs: fasting blood sugar > 120 mg/dl (1 = true; 0 = false)
- restecg: resting electrocardiographic results
 - Value 0: showing probable or definite left ventricular hypertrophy by Estes' criteria
 - Value 1: normal
 - Value 2: having ST-T wave abnormality (T wave inversions and/or ST elevation or depression of > 0.05 mV)
- thalach: maximum heart rate achieved
- exang: exercise induced angina (1 = yes; 0 = no)



14 attributes

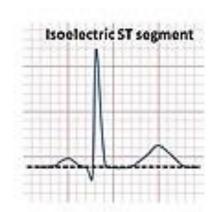
- age: age (age in years)
- sex: sex (1 = male; 0 = female)
- cp: chest pain type (4 values)
- trestbps: resting blood pressure
- chol: The person's cholesterol measurement in mg/dl
- fbs: fasting blood sugar > 120 mg/dl (1 = true; 0 = false)
- restecg: resting electrocardiographic results
 - Value 0: showing probable or definite left ventricular hypertrophy by Estes' criteria
 - Value 1: normal
 - Value 2: having ST-T wave abnormality (T wave inversions and/or ST elevation or depression of > 0.05 mV)
- thalach: maximum heart rate achieved
- exang: exercise induced angina (1 = yes; 0 = no)

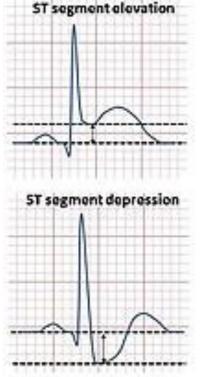




14 attributes

- oldpeak: oldpeak = ST depression induced by exercise relative to rest
- slope: the slope of the peak exercise ST segment
- ca: number of major vessels (0-3) colored by flourosopy
- thal: A blood disorder called thalassemia
 - Value 0: NULL (dropped from the dataset previously
 - Value 1: fixed defect (no blood flow in some part of the heart)
 - Value 2: normal blood flow
 - Value 3: reversible defect (a blood flow is observed but it is not normal)
- target: 0 = no disease and 1 = disease





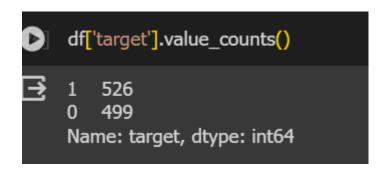


• ไม่มี Missing Value

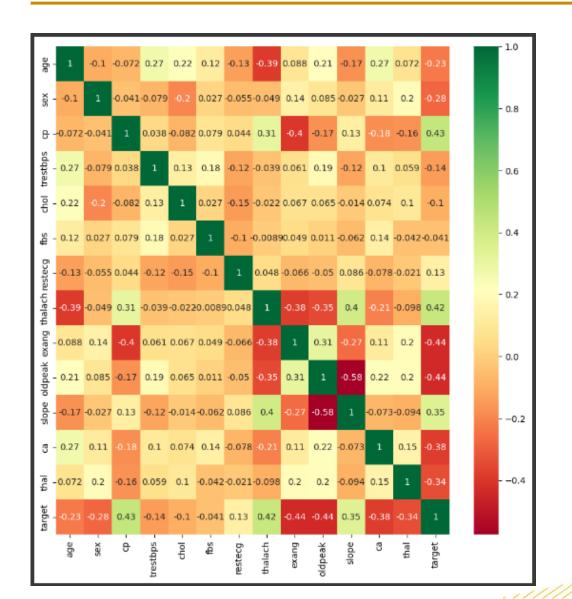
```
df.isnull().sum()
∃
              0
     sex
             0
     ср
     trestbps 0
     chol
     fbs
              0
     restecg
              0
     thalach
               0
     exang
     oldpeak
     slope
             0
     ca
     thal
             0
     target
     dtype: int64
```



- ไม่มี Missing Value
- Balanced Data

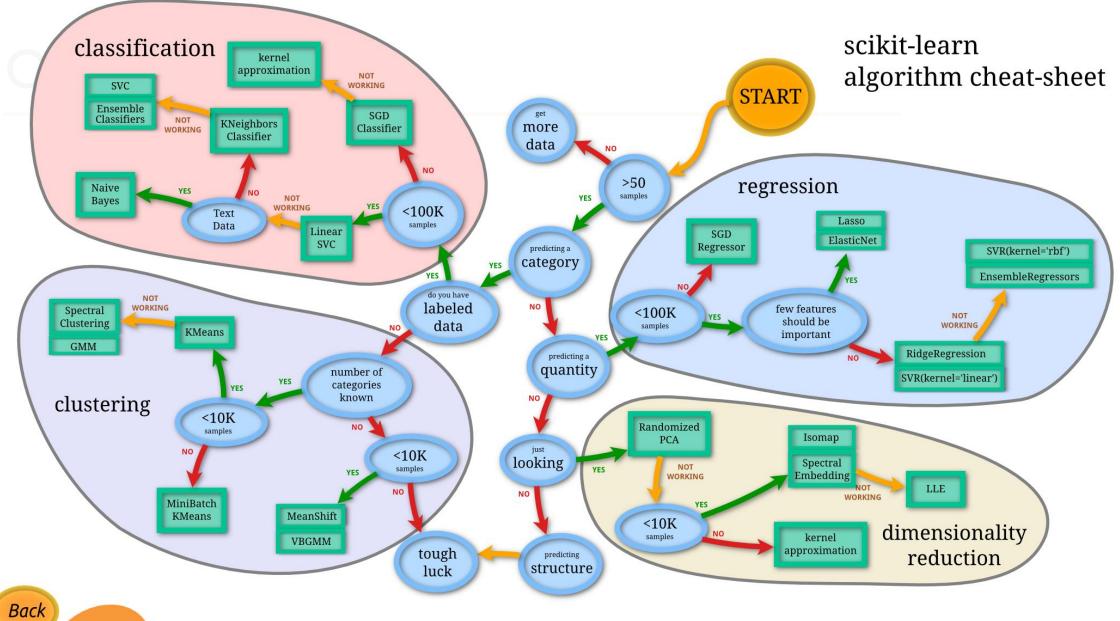






- ไม่มีความสัมพันธ์
- ไม่มีการตัด Feature









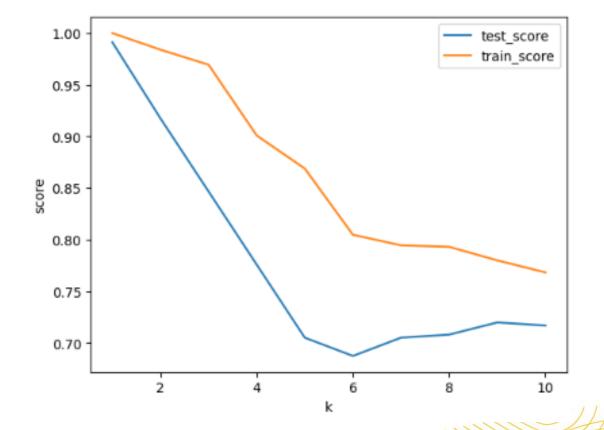
• K-Neighbors Classifier



- K-Neighbors Classifier
- เลือกค่า k



- K-Neighbors Classifier
- เลือกค่า k = 1





- K-Neighbors Classifier
- เลือกค่า k = 1
- Train-Test Split (33% Test)



- K-Neighbors Classifier
- เลือกค่า k = 1
- Train-Test Split (33% Test)
- Train Model

Result



K-Neighbors Classifier

• Accuracy = 0.96

Classifica	tion Repor precision	f1-score	support		
0	0.95	0.95	165		
1	0.96	0.96	174		

Confusion Matrix: [[159 6] [9 165]]

Result



เปรียบเทียบ Accuracy และ False Positive เพิ่มเติมกับอีก 3 models

 Support Vector Machine

Accuracy: 0.71

Classification Report:
 precision recall f1-score support

 0 0.71 0.67 0.69 165
 1 0.70 0.74 0.72 174

accuracy 0.71 339
macro avg 0.71 0.71 0.71 339
weighted avg 0.71 0.71 0.71 339

Confusion Matrix:
[[111 54]
[45 129]]

Random Forest Classifier

```
Accuracy: 0.94
Classification Report:
        precision recall f1-score support
                                 165
      1 0.94 0.95 0.95
                                 174
                                 339
  accuracy
              0.94
                                    339
 macro avg
                                    339
weighted avg
              0.94
Confusion Matrix:
[[155 10]
 9 165]]
```

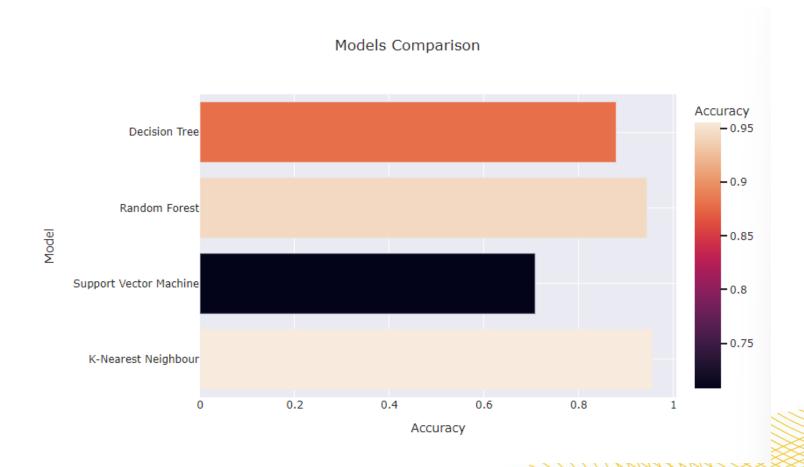
Decision Tree

```
Accuracy: 0.88
Classification Report:
        precision recall f1-score support
           0.91 0.84
                                  165
           0.86 0.92 0.89
                                  174
  accuracy
                                 339
              0.88 0.88 0.88
                                    339
  macro avq
weighted avg
               0.88
Confusion Matrix:
[[138 27]
[ 14 160]]
```

Result



เปรียบเทียบ Accuracy และ False Positive เพิ่มเติมกับอีก 3 models



Conclusion

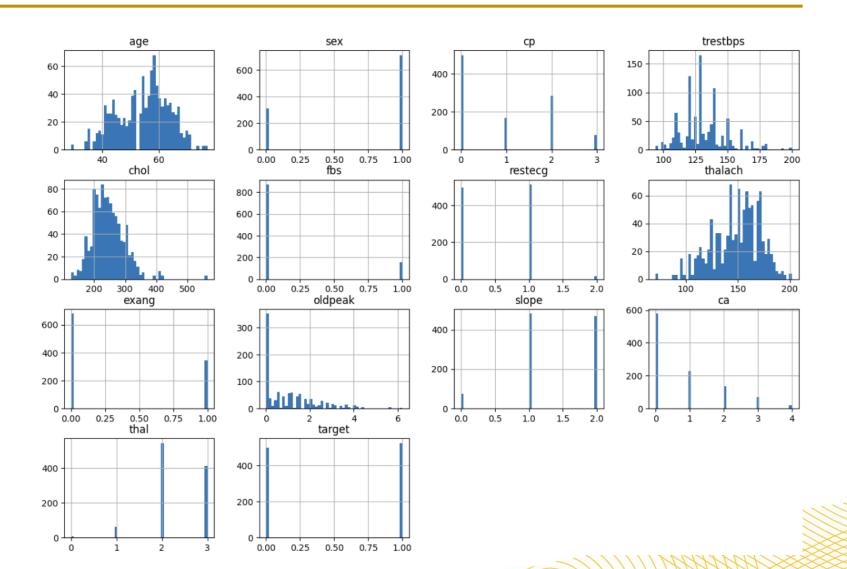


- ค่า Accuracy เท่ากับ 0.96 ค่อนข้างสูงมากเนื่องจากเลือก classifier และ parameter ได้เหมาะสม
- แต่ข้อสังเกตจาก confusion matrix ในช่อง false positive เท่ากับ 9 ค่อนข้างน่าเป็นห่วง เนื่องจากผู้ป่วยที่เป็นโรคหัวใจแต่ได้รับผลว่าไม่เป็นโรคอาจจะมีความระมัดระวังต่อพฤติกรรมที่เสี่ยงต่อ โรคน้อยกว่า ซึ่งนำไปสู่อันตรายถึงชีวิตได้ แต่ก็ต่ำที่สุดในทั้ง 4 models



Thank You for Your Attention

Q & A





	age	sex	ср	trestbps	chol	fbs	restecg	thalach	exang	oldpeak	slope	са	thal	target
count	1025.000000	1025.000000	1025.000000	1025.000000	1025.00000	1025.000000	1025.000000	1025.000000	1025.000000	1025.000000	1025.000000	1025.000000	1025.000000	1025.000000
mean	54.434146	0.695610	0.942439	131.611707	246.00000	0.149268	0.529756	149.114146	0.336585	1.071512	1.385366	0.754146	2.323902	0.513171
std	9.072290	0.460373	1.029641	17.516718	51.59251	0.356527	0.527878	23.005724	0.472772	1.175053	0.617755	1.030798	0.620660	0.500070
min	29.000000	0.000000	0.000000	94.000000	126.00000	0.000000	0.000000	71.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
25%	48.000000	0.000000	0.000000	120.000000	211.00000	0.000000	0.000000	132.000000	0.000000	0.000000	1.000000	0.000000	2.000000	0.000000
50%	56.000000	1.000000	1.000000	130.000000	240.00000	0.000000	1.000000	152.000000	0.000000	0.800000	1.000000	0.000000	2.000000	1.000000
75%	61.000000	1.000000	2.000000	140.000000	275.00000	0.000000	1.000000	166.000000	1.000000	1.800000	2.000000	1.000000	3.000000	1.000000
max	77.000000	1.000000	3.000000	200.000000	564.00000	1.000000	2.000000	202.000000	1.000000	6.200000	2.000000	4.000000	3.000000	1.000000



⋈

1 526

0 499

Name: target, dtype: int64